Sesgo de género en biografías: metodología completa del estudio

EQUIPO CALIPSO

Resumen

Las biografías profesionales de mujeres reciben más rasgos comunales y menos rasgos agénticos que las de hombres de la misma profesión: 17 diferencias confirmadas con biografías nuevas, y una métrica de potenciales sesgos en el discurso de 0,369 en mujeres frente a 0,317 en hombres (d = 0,29).

Pregunta. ¿Se describe de forma distinta a mujeres y hombres que ejercen la misma profesión?

Criterio. No se mide cómo son las personas, sino **qué elige contar quien escribe**. Un hecho de la persona no es sesgo; lo es lo que se añade, se destaca o se omite. Un tema solo cuenta como potencial sesgo si no es relevante para su trabajo, juzgado desde el propio texto.

Cómo. Un modelo de lenguaje anota cada biografía con 38 rasgos agrupados en 7 dimensiones. Se compara a mujeres y hombres dentro de cada profesión con pruebas estadísticas fijadas de antemano, en muestras que no se habían usado para formular las hipótesis.

Lo que se confirma. Marcado de género, nombre de pila, hijos, cuidado, calidez, emoción y pasión, bienestar, activismo y aficiones del hogar aparecen más en mujeres. Adjetivos de competencia, logros, liderazgo, prestigio y perfil científico y tecnológico aparecen más en hombres. La agencia diluida (M7) no se confirma.

Datos

Se usa *Bias in Bios* (De-Arteaga et al., 2019): 396.189 biografías reales en inglés de 28 profesiones, 213.543 de hombres y 182.646 de mujeres. Tras quitar los perfiles hechos con plantilla quedan 356.335.

- **Filtro de plantillas.** Los perfiles generados por directorios web (sobre todo sanitarios) no los escribe una persona, así que no se usan en ningún paso. Se detectan con reglas de palabras clave, iguales para todos los textos. No se usa el modelo para esto porque clasificaba como directorio biografías breves normales, más a menudo las de mujeres.
- **Enmascarado.** Antes de anotar, los pronombres pasan a `[X]` y los nombres de persona a `[NAME]` (con spaCy), para que el modelo no sepa el género. Solo la forma de nombrar y el uso del título se anotan sobre el texto original.
- **Control de calidad.** Cada texto se clasifica como biografía o no; los que no lo son se excluyen de los análisis.
- **Muestras equilibradas.** Cada muestra toma el mismo número de mujeres y de hombres en cada profesión, y se sortea una sola vez y se guarda. Ninguna biografía se repite entre las muestras que se comparan.

Muestra	Por profesión y género	Biografías	Válidas	Para qué

Muestra	Por profesión y género	Biografías	Válidas	Para qué
Descubrimiento (N05)	hasta 1.500	54.518	—	Encontrar palabras que distinguen a mujeres y hombres
Ronda 1	20	1.120	945	Explorar
Ronda 2	20	1.120	1.023	Confirmar la ronda 1
Ronda 3	40	2.240	2.070	Confirmar con las variables originales
Confirmación	40	2.240	2.056	Confirmar las variables revisadas (FDR 0,05)
Ampliación	40	2.240	2.054	Confirmar en otra muestra nueva (FDR 0,10)

Cómo se anota cada biografía

Un modelo de lenguaje (Qwen3.5-397B-A17B, temperatura 0) responde preguntas en inglés sobre cada biografía y devuelve las respuestas en JSON. Cada pregunta cuenta la idea aunque el texto use sinónimos.

Se hacen **tres llamadas por biografía**, porque un prompt muy largo empeora las respuestas:

1. **Forma** (texto enmascarado): vida personal, logros, lenguaje, marcado de género.
2. **Contexto** (texto enmascarado): temas que pueden ser o no relevantes para el trabajo.
3. **Nombre** (texto original): cómo se nombra a la persona y si se usa su título.

La anotación va en paralelo (8 hilos), se guarda cada 40 biografías y sigue donde lo dejó si se corta.

Tipos de pregunta. Para no confundir hechos con elecciones de quien escribe, los temas delicados no se preguntan con un sí o no:

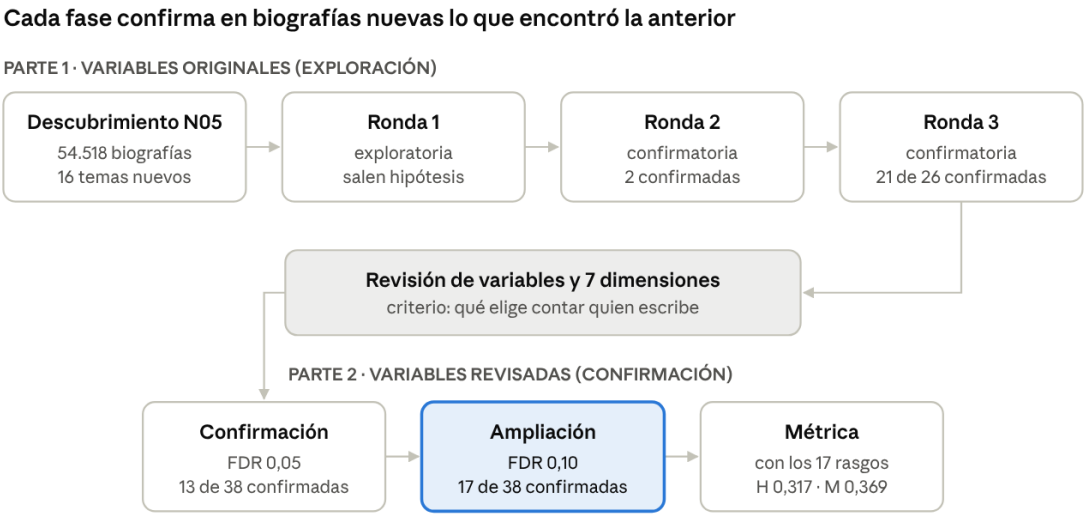
Tipo	Respuestas	Cuenta como potencial sesgo	Ejemplo
Forma	sí / no, o un recuento	que aparezca (o que falte, en lo agéntico)	se mencionan sus hijos
Encuadre	no aparece / hecho / encuadre	solo «encuadre»: el tema se añade como etiqueta, sin un hecho de su trabajo detrás	«great with kids» en un dentista general
Puesta en valor	no aplica / aplica y no se destaca / aplica y se destaca	se compara «se destaca» frente a «no se destaca»; si no aplica a su trabajo, no cuenta	perfil tecnológico de una ingeniera
Relevancia	no aparece / relevante	solo «no relevante»	comentar el

Tipo	Respuestas	Cuenta como potencial sesgo	Ejemplo
	/ no relevante		aspecto de una abogada
Título	no aplica / aplica y no lo usa / aplica y lo usa	solo entre quienes tienen título	«Dr. Smith»

Cada respuesta se convierte en **1, 0 o vacío** (no aplica). Los recuentos cuentan como 1 si son mayores que 0 para las dimensiones y la métrica, pero en los contrastes se analizan como recuentos.

Las rondas: explorar primero, confirmar después

El estudio alterna rondas **exploratorias**, que buscan qué diferencias hay, y **confirmatorias**, que comprueban esas diferencias en biografías nuevas. Si se miran muchas variables y se eligen las que salen significativas, algunas salen por azar; comprobarlas en otra muestra, con la dirección fijada antes, evita dar por buena una casualidad.



fases del estudio · 4 en la parte 1, revisión, 3 en la parte 2

La parte 1 explora con las variables originales; tras revisarlas, la parte 2 las confirma dos veces en biografías nuevas y la métrica usa lo confirmado en la ampliación.

Parte 1: exploración con las variables originales (cuaderno `sesgo_genero_parte_1`)

1. **Descubrimiento (N05).** Un clasificador aprende a distinguir textos de mujeres y de hombres con el género oculto, en 54.518 biografías no usadas en las rondas. Distingue bien en algunas profesiones (AUC 0,85 en modelo, 0,74 en medicina). Sus palabras más asociadas a cada género se agrupan en 16 temas, que pasan a ser preguntas para el modelo.
2. **Ronda 1 (exploratoria).** 40 variables teóricas de la literatura. Todo se mira, sin hipótesis previas; lo que sale se convierte en hipótesis con dirección.

3. **Ronda 2 (confirmatoria).** Biografías nuevas. Se confirman 2 hipótesis (marcado de género y nombre de pila); lo demás que sale queda como pista.
4. **Ronda 3 (confirmatoria).** Biografías reservadas antes del descubrimiento, así que N05 nunca las vio. Se prueban 26 hipótesis (réplicas, pistas de la ronda 2 y temas de N05): se confirman 21.

Revisión de variables. Al revisar casos de la parte 1 se vio que varias variables medían hechos de la persona y no elecciones de quien escribe (por ejemplo, contar «niños» en una pediatra). Se redefinieron con el criterio de relevancia para el trabajo (encuadre, puesta en valor, relevancia), se quitaron las que no eran sesgo y se agruparon en 7 dimensiones. Como las variables cambiaron, los resultados de la parte 1 ya no sirven para confirmarlas: hacen falta datos nuevos.

Parte 2: confirmación con las variables revisadas (cuaderno `sesgo_genero_parte_2`)

5. **Confirmación.** Muestra nueva, no usada en ninguna fase anterior. 38 hipótesis con dirección fijada de antemano, Benjamini-Hochberg al 0,05: se confirman 13.
6. **Ampliación.** Otra muestra nueva, sin las biografías de las rondas 1 a 3 ni de la confirmación. Mismas hipótesis, salvo excepcionalidad, que pasa al lado agéntico. El umbral de 0,10 se fijó antes de anotarla: se confirman 17. Estas 17 son las que usa la métrica.

Cambiar el umbral después de ver los resultados de la confirmación no sería válido; por eso se sacó una muestra nueva. La parte 1 no se toca: era exploratoria y con otras variables.

Variables y dimensiones finales

Los 38 rasgos se agrupan en 7 dimensiones, repartidas en dos lados: lo comunal, que se añade más a las mujeres, y lo agéntico, que se cuenta más de los hombres.

- **Comunal** (de *comunidad*): relaciones, cuidado, calidez, emoción y vida personal. Potencial sesgo: **que se añada** sin relación con el trabajo.
- **Agéntico** (de *agencia*): acción, autonomía, logro, liderazgo y estatus. Potencial sesgo: **que falte** lo que se suele contar de los hombres de esa profesión.

Ambos términos vienen de la psicología social (Bakan; Abele y Wojciszke). Ninguno es bueno ni malo en sí mismo: lo que se estudia es si se usan de forma distinta según el género.

Dimensión	Lado	Rasgos
M1 · Marcado de género	comunal	marcar su género en relación con la profesión; destacar su género como relevante; nombrarla por el nombre de pila
M2 · Vida personal y aspecto	comunal	pareja; hijos; estado civil; padres u origen; presentada a través de otra persona; aficiones; aspecto físico no relevante
M3 · Calidez y emoción	comunal	orientación al cuidado; adjetivos de calidez; palabras de emoción; motivación como pasión; bienestar o sanación como etiqueta

Dimensión	Lado	Rasgos
M4 · Temas comunales añadidos	comunal	infancia y familias como etiqueta; belleza y moda como etiqueta; activismo como etiqueta; aficiones del hogar o creativas; voluntariado
M7 · Agencia diluida	comunal	mérito atribuido a otros; logros en pasiva; verbos de apoyo; expresiones de duda; mérito compartido con la pareja
M5 · Agencia y estatus	agéntico	adjetivos de competencia; logros; liderazgo; impacto; innovación; fama y prestigio; valentía; verbos de rol activo; uso del título; excepcionalidad
M6 · Perfil técnico y empresarial puesto en valor	agéntico	perfil científico o cuantitativo; perfil tecnológico; empresa o negocio (solo si forma parte de su trabajo)

M1 va en el lado comunal porque es una marca que se pone sobre todo a las mujeres. M7 va también en ese lado porque resta protagonismo. Excepcionalidad empezó en M1 («primera mujer en…»), pero en la confirmación salió más en hombres y pasó a M5.

Descriptivas (se informan, pero no cuentan como sesgo): espacios de un solo género, título con género (*actress*), posición de la primera mención familiar, número de credenciales, experiencia, docencia, especialización, tono, y palabras de esfuerzo frente a palabras de talento. El tipo de texto es la variable de control.

Eliminadas por no medir una elección de quien escribe o no ser sesgo: riesgo militar, deporte físico, aficiones al aire libre o mecánicas, narrativa y expresión, identidad LGTBI, obstáculos de género, edad y número de frases de vida personal.

Contrastes estadísticos

Cada rasgo se compara entre mujeres y hombres **de la misma profesión**, con un modelo que controla la profesión. Así, una diferencia no se debe a que haya más mujeres en enfermería o más hombres en ingeniería.

```
\text{rasgo} \sim \text{mujer} + \text{profesión}
```

Tipo de rasgo	Modelo	Efecto que se informa
Sí / no	Regresión logística	Razón de odds (> 1 = más en mujeres)
Recuento (n.º de adjetivos, logros…)	Binomial negativa, con la longitud del texto como *offset*	Razón de tasas por palabra
Un grupo con 0 casos	Prueba exacta de Fisher	—
Menos de 10 casos en total	No se prueba	—

Prueba unilateral. Cada hipótesis tiene una dirección fijada antes de ver los datos (los rasgos comunales, más en mujeres; los agénticos, más en hombres). Solo se confirma si es significativa **y** va en esa dirección.

Corrección por comparaciones múltiples: Benjamini-Hochberg. Al probar 38 rasgos a la vez, alguno saldría significativo por azar. Benjamini-Hochberg controla la tasa de falsos descubrimientos (FDR): con un FDR del 0,05, como mucho un 5 % de las diferencias confirmadas serían falsas, en promedio; con 0,10, un 10 %.

Análisis	Dirección	Corrección
Confirmatorio, rondas 2 y 3 y confirmación	unilateral	Benjamini-Hochberg al 0,05
Confirmatorio, ampliación	unilateral	Benjamini-Hochberg al 0,10, fijado antes de anotar
Exploratorio (ronda 1 y pistas)	bilateral	Benjamini-Hochberg al 0,10
Por profesión (descriptivo)	bilateral	Benjamini-Hochberg al 0,10

Al principio se añadió Holm como comprobación más estricta, pero se quitó: con Benjamini-Hochberg basta para el objetivo del estudio, y Holm controla un error distinto (que haya al menos un falso positivo).

¿Cambia la brecha según el tipo de profesión? Las profesiones se agrupan por su % de mujeres en el dataset: menos del 35 %, entre 35 y 65 %, y más del 65 %. Una prueba de razón de verosimilitudes compara el modelo con una brecha común y el modelo con una brecha distinta en cada grupo (`profesión + mujer × tipo`).

Resultados

La ampliación confirma 17 de 38 rasgos y la confirmación 13; 9 se confirman en las dos muestras. Todos van en la dirección esperada: lo comunal, más en mujeres; lo agéntico, más en hombres.

Rasgos confirmados en alguna de las dos muestras. Los valores son de la ampliación: % de biografías, o media por biografía en los recuentos (*).

Dimensión	Rasgo	Hombres	Mujeres	Confirmación (0,05)	Ampliación (0,10)
M1	Marca su género en relación con la profesión	0,8 %	3,5 %	sí	sí
M1	Destaca su género como relevante	0,7 %	3,2 %	sí	sí
M1	Nombrada por el nombre de pila	52,7 %	58,7 %	sí	sí

Dimensión	Rasgo	Hombres	Mujeres	Confirmación (0,05)	Ampliación (0,10)
M2	Hijos	3,0 %	5,3 %	sí	sí
M2	Aficiones	10,9 %	10,9 %	sí	no
M3	Orientación al cuidado	18,0 %	24,7 %	sí	sí
M3	Adjetivos de calidez *	0,09	0,14	no	sí
M3	Palabras de emoción *	0,32	0,42	sí	sí
M3	Motivación como pasión	18,4 %	27,3 %	sí	sí
M3	Bienestar como etiqueta	0,2 %	1,3 %	no	sí
M4	Activismo como etiqueta	2,3 %	3,9 %	sí	sí
M4	Aficiones del hogar o creativas	4,7 %	6,6 %	sí	sí
M4	Voluntariado	3,9 %	3,0 %	sí	no
M5	Adjetivos de competencia *	0,49	0,38	no	sí
M5	Logros *	0,73	0,64	no	sí
M5	Liderazgo	23,1 %	19,7 %	no	sí
M5	Impacto	5,3 %	4,0 %	sí	no
M5	Innovación	10,7 %	8,7 %	sí	no
M5	Fama y prestigio	17,6 %	13,3 %	no	sí
M6	Perfil científico puesto en valor (entre quienes aplica)	27,9 %	19,2 %	no	sí
M6	Perfil tecnológico puesto en valor (entre quienes aplica)	44,1 %	32,8 %	no	sí

Lo que no se confirma.

- **M7 · Agencia diluida**: ningún rasgo en ninguna muestra.
- **Excepcionalidad**: en la confirmación salió más en hombres (5,5 % frente a 3,4 %), al revés de lo previsto; en la ampliación, ya en el lado agéntico, no llega a ser significativa (p corregida 0,14).
- **Pareja, estado civil, padres, empresa, valentía, uso del título y verbos de rol activo**: diferencias pequeñas o no significativas.
- **Aspecto físico e infancia como etiqueta**: menos de 10 casos en la ampliación, no se pueden probar.

Tipo de profesión. En la ampliación, ningún rasgo confirmado tiene una brecha distinta según el % de mujeres de la profesión, una vez corregido por comparaciones múltiples.

Métrica de potenciales sesgos en el discurso

La métrica resume cada biografía en un número de 0 a 1: 0 = no se detecta ningún potencial sesgo; 1 = se detectan todos los analizados. En la ampliación, las biografías de mujeres puntúan 0,051 más que las de hombres de su misma profesión.

```
\text{total} = 0{,}7 \cdot \text{presencia} + 0{,}3 \cdot \text{omisión}
```

- **Presencia (70 %)**: de los rasgos comunales que aplican al texto, cuánto peso suman los que aparecen.
- **Omisión (30 %)**: de los rasgos agénticos habituales en los hombres de su profesión, cuánto peso suman los que faltan.

Cómo se calcula, paso a paso

1. **Solo rasgos confirmados.** Entran los 17 confirmados en la ampliación: 11 comunales (presencia) y 6 agénticos (omisión).
2. **Tasas de referencia por profesión.** Para cada rasgo, el % de mujeres y de hombres que lo tienen en esa profesión, entre las biografías a las que aplica.
3. **Suavizado.** Con 40 biografías por grupo, una tasa por profesión es inestable. Se mezcla con la tasa general: peso de la profesión = n / (n + 40). Con 40 biografías, mitad profesión y mitad general.
4. **Peso de cada rasgo comunal** = cuánto más aparece en mujeres que en hombres de esa profesión (si no aparece más en mujeres, peso 0).
5. **Peso de cada rasgo agéntico** = su tasa en los hombres de esa profesión, si llega al 10 %; si no, 0 (no se puede omitir lo que casi nunca se cuenta).
6. **Presencia** = suma de pesos de los rasgos comunales presentes / suma de pesos de los que aplican. **Omisión** = lo mismo con los agénticos que faltan. Si en una profesión no hay ningún rasgo agéntico habitual, la omisión es 0.
7. **Validación cruzada (5 pliegues).** Si los pesos se calculan con las mismas biografías que se puntúan, la diferencia sale inflada. Por eso cada biografía se puntúa con pesos calculados sin ella (sin su quinta parte de la muestra).
8. **Profesión desconocida.** Si la profesión no es una de las 28, se usan las tasas generales.

Resultados en la ampliación (diferencia ajustada por profesión)

Parte	Hombres	Mujeres	Diferencia (IC 95 %)	d de Cohen
Total	0,317	0,369	0,051 (0,036 a 0,065)	0,29
Presencia	0,161	0,212	0,049 (0,030 a 0,068)	0,22
Omisión	0,681	0,737	0,054 (0,030 a 0,077)	0,19

Todas las diferencias tienen $p < 0{,}001$. En la confirmación, con sus 13 rasgos, la diferencia total fue parecida: 0,052 ($d = 0{,}23$). La brecha no cambia significativamente según el tipo de profesión ($p = 0{,}27$).

Es mayor en interiorismo (0,19), DJ y pastor/a (0,12), y se invierte en modelo (−0,05), también en las dos muestras.

Archivos y herramientas

Todo va en la misma carpeta (`prueba_arantxa`); la dirección y el token del modelo se leen del archivo `.env` y nunca se escriben en el código.

Archivo	Qué hace	Qué produce
`sesgo_genero_parte_1.ipynb`	Datos, filtro de plantillas, N05 y rondas 1 a 3 con las variables originales. No hace falta volver a ejecutarlo.	`cache/`, resultados de las rondas 1 a 3
`sesgo_genero_parte_2.ipynb`	Muestra nueva, anotación con las variables revisadas, confirmatorio, descriptivas, dimensiones, gráficos radiales y métrica. Se elige la fase con `FASE = "confirmacion"` o `"ampliacion"`.	`anotaciones_{fase}.csv`, `resultados/*_{fase}.csv` y gráficos
`detector_sesgo_genero.ipynb`	Analiza una biografía: métrica, gráfico de flechas, tabla de dimensiones y rasgos, y el texto con los rasgos resaltados. Compara con su profesión y con todas.	Resultados en el propio cuaderno
`app_gradio.py`	La misma idea en una web: biografías en inglés o en castellano. El castellano se traduce al inglés antes de analizarlo, porque las biografías de referencia están en inglés y el género en castellano no se puede ocultar. Se lanza desde un terminal con `python app_gradio_v3.py`.	Enlace temporal `gradio.live` (público: no compartirlo)

La referencia del detector y de la app son las biografías anotadas en la confirmación y la ampliación; los rasgos de la métrica, los 17 confirmados en la ampliación.

Limitaciones

- **El modelo puede equivocarse.** Las anotaciones no se han validado a mano de forma sistemática; los rasgos poco frecuentes son los más difíciles.

- **Efectos pequeños.** La diferencia en la métrica es real pero moderada (d = 0,29). Una biografía aislada no demuestra sesgo: la métrica señala potenciales sesgos.
- **Quién escribe.** No se sabe si cada biografía la escribió la propia persona u otra.
- **Inglés y género binario.** El dataset está en inglés y solo distingue mujer y hombre. Los textos en castellano de la app pasan por una traducción.
- **40 biografías por grupo.** Bastan para el conjunto, pero no para afirmar diferencias en cada profesión por separado.
- **Excepcionalidad** cambió de lado después de ver la confirmación; se probó en la ampliación con su nuevo lado y no se confirmó, así que no entra en la métrica.
- **Tamaños muestrales reducidos.**
- **Posible mejora en la optimización.** Las rondas podrían reducirse y comparar si los resultados siguen siendo fiables.

Glosario

Término	Significado
Exploratorio	Análisis para buscar diferencias, sin hipótesis previas. Lo que sale es una pista, no una conclusión.
Confirmatorio	Comprobación de hipótesis fijadas de antemano, en biografías nuevas.
Unilateral	La prueba solo busca la diferencia en la dirección prevista.
p corregida	Valor p ajustado por haber hecho muchas pruebas a la vez.
FDR (Benjamini-Hochberg)	Proporción esperada de falsos descubrimientos entre lo confirmado.
Razón de odds	Cuántas veces más probable es el rasgo en mujeres que en hombres de la misma profesión (> 1 = más en mujeres).
Binomial negativa	Modelo para recuentos (n.º de adjetivos, logros…) que tiene en cuenta la longitud del texto.
AUC	Capacidad de un clasificador para distinguir dos grupos: 0,5 = nada; 1 = perfecta.
Suavizado	Mezclar la tasa de una profesión con la general para que una muestra pequeña no dé pesos extremos.
Validación cruzada	Puntuar cada biografía con pesos calculados sin ella, para no inflar las diferencias.
d de Cohen	Tamaño de una diferencia en desviaciones típicas: 0,2 pequeña; 0,5 media.
Comunal / agéntico	Rasgos de relación y cuidado / rasgos de acción, logro y

Término	Significado
	estatus.